

Raport z projektu

Przewidywanie przeżywalności pasażerów Titanica

Yevhen Koval (s30874)

Podstawy Uczenia Maszynowego

Spis Treści

1	Opis problemu	3
1.1	Krótki opis problemu i jego kontekstu	3
1.2	Kto i w jaki sposób może skorzystać z tego modelu?	3
1.3	Dlaczego problem wydaje się interesujący?	3
2	Dane	3
2.1	Źródła danych i ocena ich wiarygodności	3
2.2	Krótką analizę opisową danych	3
2.3	Uzasadnienie: w jaki sposób dane mogą pomóc?	3
3	Sposób rozwiązania problemu	4
3.1	Krótki opis wybranych modeli wraz z uzasadnieniem	4
3.2	Etapy realizacji projektu	4
3.3	Miary ewaluacji (oceny jakości) modeli	6
4	Dyskusja wyników i dogłębna analiza modeli	8
4.1	1. Analiza modelu: Las Losowy (Random Forest)	8
4.2	2. Analiza modelu: Regresja Logistyczna	9
4.3	3. Analiza modelu: Drzewo Decyzyjne	10
4.4	Porównanie modeli i ostateczne wnioski	11
5	Podsumowanie	13
5.1	Co się udało?	13
5.2	Jakie były problemy? Jak je rozwiązaliśmy?	13
5.3	W jaki sposób może być to wykorzystane w przyszłości?	13
6	Załączniki	14
6.1	Załącznik 1. Eksploracyjna analiza danych (EDA)	14
6.2	Załącznik 2. Wyniki z działania modelu (Feature Importance i inne)	20

1 Opis problemu

1.1 Krótki opis problemu i jego kontekstu

Projekt dotyczy katastrofy statku RMS Titanic z 1912 roku. Zadaniem było zbudowanie modelu predykcyjnego (klasyfikatora), który potrafi przewidzieć, czy dana osoba przeżyła katastrofę (1), czy nie (0). Robimy to na podstawie dostępnych danych o pasażerach. Głównym celem jest znalezienie schematów i zasad, które w tamtym momencie decydowały o przetrwaniu.

1.2 Kto i w jaki sposób może skorzystać z tego modelu?

Model i płynące z niego wnioski mogą przydać się osobom badającym historię, żeby sprawdzić, czy słynna zasada „kobiety i dzieci najpierw” była faktycznie rygorystycznie stosowana. Można też na liczbach zobaczyć, jak majątek (klasa biletu) wpływał na szanse ratunku. Ponadto, mój sposób tworzenia nowych zmiennych (np. mnożnik klasy i wieku) może posłużyć jako fajny przykład w dziedzinie Machine Learning.

1.3 Dlaczego problem wydaje się interesujący?

Problem ten jest bardzo ciekawy, ponieważ zmusza do wymyślania nowych informacji na podstawie tych, które już mamy. Same, surowe dane mają sporo braków (np. brakuje wieku bardzo wielu osób). Żeby dobrze odgadnąć brakujące informacje, musimy zwrócić uwagę na detale, takie jak tytuły grzecznościowe („Miss”, „Master” czy „Dr”), i na ich podstawie odtworzyć profil pasażera.

2 Dane

2.1 Źródła danych i ocena ich wiarygodności

Zbiór danych pochodzi ze znanej platformy OpenML. Zawiera on dane o ponad 1300 pasażerach statku. Informacje te są wiarygodne historycznie, chociaż mają trochę braków (szczególnie w kolumnach z wiekiem i numerem kabiny). Wynika to po prostu z nieidealnych, dawnych metod zbierania informacji i zaginięcia części dokumentów.

2.2 Krótka analiza opisowa danych

Na początku nasz zbiór miał 14 kolumn, m.in. pclass (klasa kabiny), name (imię i nazwisko), sex (płeć), age (wiek), sibsp (rodzeństwo/małżonkowie), parch (rodzice/dzieci), fare (cena biletu). Szybko zauważyłem, że brakuje wieku u wielu pasażerów. Postanowiłem sprytnie uzupełnić te luki, wyciągając tytuły z kolumny z imieniem i nazwiskiem. Zauważyłem też, że w kolumnie fare są bardzo duże, odstające wartości u najbogatszych pasażerów.

2.3 Uzasadnienie: w jaki sposób dane mogą pomóc?

Dane te mówią nam zarówno o cechach biologicznych (wiek, płeć), jak i społecznych (klasa, wielkość rodziny). Podczas ratunku na morzu na początku XX wieku oba te elementy odgrywały kluczową rolę. Algorytmy uczenia maszynowego potrafią łatwo wyłapać z tych danych zasady – na przykład model od razu zauważy, że małe dziecko z pierwszej klasy miało ogromne szanse na przeżycie, w przeciwieństwie do starszego mężczyzny z trzeciej klasy.

3 Sposób rozwiązania problemu

3.1 Krótki opis wybranych modeli wraz z uzasadnieniem

W celu znalezienia najlepszego rozwiązania, zdecydowałem się przetestować i porównać trzy różne modele klasyfikacyjne:

1. **Las Losowy (Random Forest Classifier):** Jest to mój główny model. Wybrałem go, ponieważ jest bardzo odporny na przeuczenie i świetnie radzi sobie z nieliniowymi zależnościami. Działa poprzez budowanie wielu drzew decyzyjnych i wyciąganie z nich wspólnego wniosku, co zazwyczaj daje najwyższą skuteczność.
2. **Drzewo Decyzyjne (Decision Tree Classifier):** Wybrałem ten model ze względu na jego wysoką interpretowalność. Pozwala on „zobaczyć”, jak algorytm podejmuje decyzje (np. płeć jako pierwszy podział). Jest to świetny punkt odniesienia dla bardziej złożonych modeli.
3. **Regresja Logistyczna (Logistic Regression):** To klasyczny model statystyczny. Użyłem go, aby sprawdzić, jak poradzi sobie podejście liniowe. Jest on bardzo szybki i pozwala łatwo ocenić wpływ poszczególnych cech (np. o ile konkretnie bycie kobietą zwiększa szanse na przeżycie) za pomocą współczynników.

3.2 Etapy realizacji projektu

Proces budowy modeli podzieliłem na kilka kluczowych etapów, z których każdy miał istotny wpływ na ostateczną skuteczność klasyfikacji. Poniżej przedstawiam szczegółowy opis wykonanych prac wraz z fragmentami kodu implementującymi daną logikę.

1. **Akwizycja i wstępne czyszczenie danych:** Dane zostały wczytane z lokalnego pliku `.csv`. Pierwszym problemem, jaki napotkałem, były znaki zapytania („?”), które w tym zbiorze oznaczały brakujące wartości. Musiałem je zamienić na standardowe obiekty `NaN`, aby biblioteki do analizy danych mogły je prawidłowo rozpoznać.

```
df = pd.read_csv("titanic.csv")
df.replace('?', np.nan, inplace=True)

# Konwersja na typy numeryczne
num_cols = ['age', 'fare']
for col in num_cols:
    df[col] = pd.to_numeric(df[col], errors='coerce')
```

2. **Inżynieria cech (Feature Engineering):** W celu wyciągnięcia głębszych informacji ze zbioru, przeprowadziłem ekstrakcję tytułów grzecznościowych z nazwisk pasażerów. Pozwoliło to na lepsze zrozumienie statusu społecznego i wieku osób. Dodatkowo stworzyłem zmienną `Family.Size` oraz autorski wskaźnik `MPC`.

```
# Ekstrakcja tytułu
df['Title'] = df['name'].str.extract(r' ([A-Za-z]+)\.', expand=False)

# Wielkość rodziny i wskaźnik MPC
df['Family.Size'] = df['parch'] + df['sibsp'] + 1
df['MPC'] = df['age'] * pd.to_numeric(df['pclass'])
```

3. **Inteligentne uzupełnianie braków (Imputacja):** Największym wyzwaniem był brakujący wiek. Zamiast wpisywać wszystkim taką samą średnią, napisałem funkcję, która przypisuje wiek na podstawie płci oraz tytułu (np. inna średnia dla młodych chłopców z tytułem „Master”, a inna dla dorosłych mężczyzn).

```
def impute_age(row, df):
    if pd.notnull(row['age']):
        return row['age']
    title = row['Title']
    # Przykład: średnia dla panny (Miss) bez dzieci
    if title == 'Miss' and float(row['parch'] or 0) == 0:
        return df[(df['Title'] == 'Miss') & (df['parch'] == 0)][['age']].mean()
    # ... pozostała logika dla Master, Mr, Mrs ...
    return df[df['sex'] == row['sex']][['age']].mean()
```

4. **Zarządzanie wartościami odstającymi:** Aby ekstremalnie wysokie ceny biletów nie zaburzały procesu nauki, zastosowałem winsoryzację (przycięcie) cen do poziomu 99. percentyla. Podobnie postąpiłem z wiekiem, ograniczając go do 67 lat.

```
df.loc[df['age'] > 67, 'age'] = 67
fare_cap = df['fare'].quantile(0.99)
df.loc[df['fare'] > fare_cap, 'fare'] = fare_cap
```

5. **Przygotowanie danych do modeli (Preprocessing):** Ostatnim krokiem przed trenowaniem była normalizacja danych liczbowych, aby miały ten sam zakres (0-1), oraz zamiana cech kategorycznych na format zrozumiały dla komputera.

```
# One-Hot Encoding dla zmiennych tekstowych
X = pd.get_dummies(X, columns=['sex', 'pclass', 'Title', 'embarked'], drop_first=True)

# Skalowanie MinMax
scaler = MinMaxScaler()
X[num_features_to_scale] = scaler.fit_transform(X[num_features_to_scale])
```

6. **Trenowanie, dobór hiperparametrów i ewaluacja:** Zbiór danych podzieliłem w proporcji 80% (zbiór uczący) do 20% (zbiór testowy). Następnie zdefiniowałem i wytrenowałem trzy różne klasyfikatory. Zamiast używać domyślnych ustawień, dla każdego z modeli celowo dobrałem specyficzne hiperparametry, aby zapobiec zjawisku przeuczenia (overfittingu) i wymusić lepszą generalizację na nowych danych.

A. Las Losowy (Random Forest)

```
rf_model = RandomForestClassifier(
    n_estimators=150,
    max_depth=6,
    min_samples_split=4,
    random_state=42
)
```

- **n_estimators=150:** Zwiększyłem liczbę drzew z domyślnych 100 do 150. Większa „rada” drzew uśrednia wyniki, co daje bardziej stabilną i wiarygodną predykcję, minimalizując wpływ pojedynczych, nietypowych obserwacji.
- **max_depth=6:** To najważniejszy parametr zapobiegający przeuczeniu. Ograniczenie głębokości do 6 poziomów sprawia, że model nie uczy się danych treningowych „na pamięć”, lecz wyłapuje tylko najważniejsze, ogólne reguły.
- **min_samples_split=4:** Węzeł musi zawierać co najmniej 4 próbki, aby mógł zostać podzielony dalej. Zapobiega to tworzeniu reguł dla pojedynczych, specyficznych pasażerów.

B. Drzewo Decyzyjne (Decision Tree)

```
dt_model = DecisionTreeClassifier(  
    max_depth=5,  
    min_samples_split=4,  
    random_state=42  
)
```

- **max_depth=5:** Pojedyncze drzewa są niezwykle podatne na przeuczenie. Ustalenie głębokości na poziomie 5 jest kompromisem – pozwala zachować wysoką czytelność (możliwość narysowania i zrozumienia całego drzewa przez człowieka), jednocześnie odcinając zbytnio szczegółowe i zaszumione gałęzie na samym dole.

C. Regresja Logistyczna (Logistic Regression)

```
lr_model = LogisticRegression(  
    max_iter=1000,  
    random_state=42  
)
```

- **max_iter=1000:** Algorytm regresji logistycznej szuka optymalnych wag iteracyjnie (krok po kroku). Domyślna wartość (100 iteracji) w bibliotece scikit-learn często okazuje się zbyt mała dla zbiorów po transformacji One-Hot Encoding, co skutkuje błędem braku zbieżności (convergence warning). Zwiększenie tego limitu do 1000 daje pewność, że algorytm matematycznie „dotrze” do najlepszego możliwego rozwiązania.

Po zdefiniowaniu tych parametrów, każdy z modeli został wytrenowany za pomocą metody `.fit(X_train, y_train)`, a następnie oceniony za pomocą predykcji `.predict(X_test)` na nienaruszonym zbiorze testowym.

3.3 Miary ewaluacji (oceny jakości) modeli

Podstawowym kryterium wyboru i oceny klasyfikatorów w tym projekcie była ogólna skuteczność (*Accuracy*), z zakładanym progiem minimalnym na poziomie 80%. Należy jednak pamiętać, że problem przeżywalności na statku Titanic charakteryzuje się silnym niezbalansowaniem klas. Liczba pasażerów, którzy ponieśli śmierć (klasa 0), znacznie przewyższa liczbę osób ocalałych (klasa 1).

W takich sytuacjach poleganie wyłącznie na ogólnej skuteczności może prowadzić do tzw. paradoksu dokładności. Model, który „w ciemno” zakładałby, że każdy pasażer zginął, osiągnąłby stosunkowo wysoką dokładność, będąc jednocześnie całkowicie bezużytecznym. Z tego powodu do pełnej i rzetelnej ewaluacji wykorzystałem zestaw miar opartych na wartościach z macierzy pomyłek (Confusion Matrix).

Fundament ewaluacji – elementy Macierzy Pomyłek: Wszystkie zaawansowane metryki opierają się na czterech podstawowych wartościach zliczanych przez model podczas testowania predykcji:

- **TP (True Positives / Prawdziwie Pozytywne):** Model przewidział przeżycie, i pasażer faktycznie przeżył.
- **TN (True Negatives / Prawdziwie Negatywne):** Model przewidział śmierć, i pasażer faktycznie zginął.
- **FP (False Positives / Fałszywie Pozytywne):** Błąd I rodzaju. Model optymistycznie przewidział przeżycie, ale pasażer zginął.
- **FN (False Negatives / Fałszywie Negatywne):** Błąd II rodzaju. Model pesymistycznie przewidział śmierć, ale pasażer zdołał się uratować.

Na podstawie powyższych wartości wyliczyłem następujące wskaźniki jakości dla każdego z trzech algorytmów:

1. Skuteczność ogólna (Accuracy) Stanowi całkowity odsetek poprawnych predykcji (zarówno poprawnie wytypowanych ocalałych, jak i ofiar) w stosunku do wszystkich przypadków w zbiorze testowym.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

2. Precyzja (Precision) Metryka ta odpowiada na pytanie: „Spośród wszystkich pasażerów, których model uznał za ocalałych, ilu faktycznie przeżyło?”. Wysoka precyzja oznacza, że algorytm jest bardzo ostrożny w rozdawaniu „wyroków życia” i rzadko popełnia błąd fałszywego alarmu (FP).

$$\text{Precision} = T \frac{P}{TP + FP}$$

3. Czulość (Recall / Sensitivity) Metryka ta odpowiada na pytanie: „Spośród wszystkich pasażerów, którzy w rzeczywistości ocaleli, jak duży odsetek zdołał wykryć algorytm?”. W kontekście Titanica czulość jest miarą krytyczną, ponieważ pokazuje, czy model nie „uśmiercił” zbyt wielu osób, którym w rzeczywistości udało się wejść do szalup ratunkowych (minimalizacja błędów FN).

$$\text{Recall} = T \frac{P}{TP + FN}$$

4. F1-Score Ponieważ poprawa precyzji często odbywa się kosztem spadku czulości (i na odwrót), do ostatecznej oceny stosuje się miarę F1-Score. Jest to średnia harmoniczna z precyzji i czulości. Daje ona pełny, obiektywny obraz jakości modelu, znacznie lepiej radząc sobie z nierównomiernym rozkładem ofiar i ocalałych niż zwykle *Accuracy*.

$$F_1 = 2c \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

5. Krzywa ROC i wskaźnik AUC Krzywa ROC (Receiver Operating Characteristic) to graficzna reprezentacja skuteczności modelu, obrazująca relację między odsetkiem prawdziwie pozytywnych (TPR) a odsetkiem fałszywie pozytywnych (FPR) przy różnych progach odcięcia prawdopodobieństwa. Do ostatecznego rankingu modeli użyłem wskaźnika **AUC** (Area Under the Curve), czyli pola powierzchni pod tą krzywą. Wartość AUC równa 0.5 oznacza model losowy, natomiast wartość zbliżająca się do 1.0 oznacza klasyfikator idealnie odróżniający pasażerów ocalałych od zmarłych.


4 Dyskusja wyników i dogłębna analiza modeli

W tej sekcji przedstawiam szczegółowe wyniki dla każdego z wytrenowanych klasyfikatorów wraz z interpretacją ich wewnętrznego działania.

4.1 1. Analiza modelu: Las Losowy (Random Forest)


Skuteczność (Accuracy): 80.53%

Las Losowy okazał się najskuteczniejszym modelem, jako jedyny spełniając wymóg przekroczenia 80% dokładności. Jego przewaga polega na budowie wielu zróżnicowanych drzew decyzyjnych, co chroni go przed szumem informacyjnym.



Wykres: Najważniejsze atrybuty decydujące o przeżyciu z perspektywy algorytmu Random Forest.

Z powyższego wykresu Feature Importance jasno wynika, że algorytm uznał płeć (**sex_male**) za absolutnie kluczową. Zaraz za nią znalazł się autorski wskaźnik MPC (wiek połączony z klasą) oraz cena zapłaconego biletu (**fare**). Oznacza to, że inżynieria cech odegrała kluczową rolę w sukcesie tego modelu.




Wykres: Częstkowa Zależność (Partial Dependence Plot) dla Lasu Losowego.

Wykres PDP ujawnia, w jaki sposób model interpretuje nieliniowości. Zależność szansy na przeżycie od ceny biletu nie rośnie w nieskończoność. Przejście z biletu najtańszego na bilet średniej klasy drastycznie podnosi szanse, ale od pewnego wysokiego pułapu cenowego wykres ulega wypłaszczeniu. Model „zrozumiał”, że ekstremalne bogactwo nie dawało już wyższej gwarancji ratunku w porównaniu do standardowej pierwszej klasy.

4.2 2. Analiza modelu: Regresja Logistyczna


Skuteczność (Accuracy): 77.48%

Regresja Logistyczna to model liniowy, który pozwala w bardzo czytelny sposób ocenić, jak dana cecha wpływa na szanse przetrwania, poprzez wyliczenie wag (współczynników).



Wykres: Wagi współczynników w modelu Regresji Logistycznej.

Atrybuty widoczne po prawej stronie wykresu (np. tytuł „Mrs”, bycie kobietą, wysoka klasa) to cechy „ciągnące” szanse pasażera na przeżycie w górę. Z kolei długie paski po lewej stronie (tytuł „Mr”, płeć męska, 3 klasa) to cechy obniżające to prawdopodobieństwo. Wnioski te pokrywają się idealnie z prawdą historyczną.



Wykres: Krzywa kalibracji dla Regresji Logistycznej.


Krzywa kalibracji dowodzi, że chociaż model ma niższą dokładność ogólną, to jest znakomicie „zestrojony”. Jeśli algorytm szacuje szanse danej grupy pasażerów na 60%, to faktycznie około 60% z nich przeżyło. Model nie jest „zbyt pewny siebie” w sytuacjach granicznych.

4.3 3. Analiza modelu: Drzewo Decyzyjne

Skuteczność (Accuracy): 77.10%

Drzewo decyzyjne osiągnęło najniższy wynik, co jest częstym zjawiskiem w przypadku pojedynczych estymatorów podatnych na przeuczenie, jednak jego ogromną zaletą jest pełna interpretowalność wizualna.

Struktura Drzewa Decyzyjnego (wycinki pierwszych 3 poziomów)




Wykres: Fragment struktury decyzyjnej pojedynczego drzewa.


Drzewo w sposób transparentny pokazuje nam, jak „myśli” maszyna. Analizując węzły od góry, widać, że pierwszym i najważniejszym podziałem jest sprawdzenie płci pasażera. Kobiety są kierowane do „bezpieczniejszych” liści drzewa, z kolei mężczyźni niemal natychmiast trafiają na ścieżki kończące się werdyktem negatywnym.

4.4 Porównanie modeli i ostateczne wnioski

Aby podjąć ostateczną decyzję o wyborze najlepszego rozwiązania, zestawilem wszystkie trzy modele na wspólnych wykresach ewaluacyjnych.




Wykres: Bezpośrednie porównanie dokładności (Accuracy) przetestowanych algorytmów.



Wykres: Porównanie krzywych ROC oraz wartości parametru AUC.

Krzywa ROC i wartość AUC (Area Under the Curve) stanowią ostateczny test skuteczności separacji klas. Las Losowy osiągnął najwyższe AUC (0.869), udowadniając swoją wyższość nad Regresją (0.856) i Drzewem (0.845).



Wykres: Zestawienie macierzy pomyłek (Confusion Matrices).

Wnioski z porównania: Analiza macierzy pomyłek ujawnia wspólną słabość wszystkich modeli – znacznie lepiej radzą sobie one z odgadywaniem ofiar niż ocalałych. Z perspektywy modelu bezpieczniej jest założyć, że pasażer nie przeżył, ponieważ na Titanicu statystycznie zginęło znacznie więcej osób (tzw. problem niezbalansowanych klas).

Jednak to właśnie **Las Losowy** okazał się najbardziej wszechstronny. Zdolał on ograniczyć liczbę fałszywie negatywnych predykcji (sytuacji, gdzie model „uśmiercił” osobę, która faktycznie przeżyła). Jego zdolność do bezproblemowego wychwytywania nieliniowych relacji – takich jak wypłaszczenie wagi ceny biletu dla klasy najbogatszej – sprawiła, że jako jedyny pokonał granicę 80% skuteczności, stając się modelem finalnym i rekomendowanym w tym projekcie.

5 Podsumowanie

5.1 Co się udało?

Głównym sukcesem projektu było pomyślne zrealizowanie postawionego zadania i przekroczenie założonego progu 80% skuteczności – ostateczny model Lasu Losowego osiągnął wynik 80.53% na zbiorze testowym. Zamiast wpisywać tam jedną ogólną średnią dla wszystkich, napisałem funkcję wyciągającą tytuły grzecznościowe (takie jak Mr, Mrs, Miss czy Master) bezpośrednio z imion i nazwisk. Pozwoliło to zachować logiczny podział i przypisać młodym chłopcom czy pannom wiek bardzo bliski rzeczywistości, co znacznie ułatwiło modelom poprawne klasyfikowanie. Udało mi się również sprawnie przygotować cały potok przetwarzania danych – od czyszczenia, przez skalowanie MinMax, aż po zakodowanie zmiennych kategoriowych, co zapewniło stabilną naukę dla wszystkich trzech badanych algorytmów.

5.2 Jakie były problemy? Jak je rozwiązaliśmy?

Największym problemem pod koniec pracy okazał się tak zwany szum informacyjny, wynikający z podania modelom zbyt wielu bardzo podobnych zmiennych. W pewnym momencie algorytmy dostawały jednocześnie dokładny wiek, stworzoną przeze mnie osobną grupę wiekową oraz wyliczony wskaźnik MPC. Powodowało to nadmierne skorelowanie cech, przez co prostsze modele (szczególnie pojedyncze drzewo decyzyjne) zaczynały uczyć się danych na pamięć i działały gorzej. Rozwiązałem ten problem w prosty sposób: usunąłem zduplikowane koszyki wiekowe, pozostawiając surowy wiek oraz interakcję MPC, a w wolne miejsce dodałem informację o porcie początkowym statku. To dało modelom nową, wartościową wiedzę i od razu podniosło skuteczność. Dodatkowo, podczas pisania kodu musiałem bardzo uważać na problem wycieku danych (data leakage) – na etapie przygotowania macierzy X musiałem całkowicie odciąć i odseparować zmienną docelową „survived”, aby modele przypadkowo nie poznały odpowiedzi przed rozpoczęciem testów.


5.3 W jaki sposób może być to wykorzystane w przyszłości?

Projekt można dalej rozwijać na kilka ciekawych sposobów. Bardzo obiecującym krokiem byłoby zaawansowane grupowanie pasażerów po numerach biletów. Wiele osób podróżowało wspólnie ze znajomymi lub jako służba z arystokracją – nie łączyły ich więzy rodzinne (więc zmienna Family.Size ich nie wyłapywała), ale posiadali ten sam numer biletu. Sprawdzenie, jak podróżowanie w takich nieoficjalnych grupach wpływało na szanse ratunku, mogłoby przynieść bardzo ciekawe wnioski historyczne. Kolejnym krokiem technicznym byłoby porzucenie klasycznych algorytmów na rzecz nowoczesnych metod boostingowych, takich jak XGBoost czy LightGBM, które potrafią wyciągnąć jeszcze wyższą skuteczność z danych tabelarycznych. Sam schemat postępowania z tego projektu – radzenie sobie z ogromnymi brakami w danych oraz inżynieria cech demograficznych – można z powodzeniem wykorzystać dzisiaj w biznesie, na przykład w firmach ubezpieczeniowych do dokładniejszego szacowania ryzyka i tworzenia profili klientów.

6 Załączniki

6.1 Załącznik 1. Eksploracyjna analiza danych (EDA)


Zgodnie z wymogami projektu, przed przystąpieniem do budowy modelu wykonałem pełną eksploracyjną analizę danych, aby lepiej zrozumieć zależności między cechami pasażerów a ich szansami na przeżycie. Poniżej zamieszczam kluczowe wizualizacje z tego procesu wraz z kodem, który je wygenerował.



Wykres 1. Szansa na przeżycie w zależności od płci. Wykres w typie mozaikowym pokazuje, że płeć żeńska stanowiła priorytet w akcji ratunkowej.

```
# 1. Płeć vs Przeżycie
plt.figure(figsize=(6, 5))
sns.histplot(data=df, x='sex', hue='survived', multiple='fill', shrink=0.8,
palette='Set2')
plt.title('Szansa na przeżycie w zależności od płci')
plt.ylabel('Proporcja')
plt.savefig('eda_sex_survived.png', dpi=300)
plt.close()
```


Wykres ten w formie proporcjonalnego wykresu mozaikowego (wypełnionego do 100%) obrazuje najbardziej drastyczną różnicę w szansach na przeżycie w całym zbiorze danych. Na pierwszy rzut oka widać, że płeć była czynnikiem niemalże deterministycznym podczas ewakuacji statku. W przypadku kobiet, proporcja osób ocalałych (kolor pomarańczowy) zdecydowanie dominuje, przekraczając 70% całej populacji pasażerek. Z kolei w przypadku mężczyzn sytuacja jest odwrotna – przytłaczająca większość, bo ponad 80%, poniosła śmierć w katastrofie. Taki rozkład danych jest bezpośrednim odzwierciedleniem bezwzględnie egzekwowanej zasady morskiej „kobiety i dzieci najpierw”.



Wykres 2. Wpływ klasy biletu na szansę przeżycia. Widoczna jest degradacja szans wraz ze spadkiem prestiżu kabiny.

```
# 2. Klasa vs Przeżycie
plt.figure(figsize=(6, 5))
sns.histplot(data=df, x='pclass', hue='survived', multiple='fill', shrink=0.8,
palette='Set2', discrete=True)
plt.title('Szansa na przeżycie w zależności od klasy biletu')
plt.xticks([1, 2, 3])
plt.ylabel('Proporcja')
plt.savefig('eda_pclass_survived.png', dpi=300)
plt.close()
```


Przedstawiona wizualizacja ukazuje silną korelację między statusem socjoekonomicznym pasażera, reprezentowanym przez klasę biletu, a jego prawdopodobieństwem ocalenia. Analizując pierwszy słupek, reprezentujący klasę 1, wyraźnie widać, że ponad 60% najbogatszych pasażerów przeżyło katastrofę. W klasie 2 szanse te zauważalnie maleją, oscylując w okolicach 40-45%. Najbardziej tragiczny obraz wyłania się jednak w klasie 3, gdzie odsetek ofiar śmiertelnych jest przytłaczający i przekracza 70%.



Wykres 3. Szansa na przeżycie w zależności od portu zaokrętowania. Pasażerowie z Cherbourg (C) mieli statystycznie wyższe szanse.

```
# 3. Port (Embarked) vs Przeżycie
plt.figure(figsize=(6, 5))
df_embarked = df.dropna(subset=['embarked'])
sns.histplot(data=df_embarked, x='embarked', hue='survived', multiple='fill', shrink=0.8,
palette='Set2')
plt.title('Szansa na przeżycie w zależności od portu zaokrętowania')
plt.ylabel('Proporcja')
plt.savefig('eda_embarked_survived.png', dpi=300)
plt.close()
```


Wykres proporcjonalny dla portów zaokrętowania (Cherbourg, Queenstown, Southampton) dostarcza bardzo interesujących, nieoczywistych wniosków. Wyróżnia się tutaj przede wszystkim port w Cherbourg (C), dla którego odsetek ocalałych jest najwyższy i przekracza 50%. Z kolei pasażerowie wsiadający w Southampton (S) odnotowali najniższy współczynnik przeżywalności. Aby poprawnie zinterpretować ten wykres, należy spojrzeć na niego przez pryzmat struktury biletów. Wysoka przeżywalność w Cherbourg nie wynika z faktu samego portu, lecz z tego, że w tym francuskim mieście na pokład wsiadała nieproporcjonalnie duża liczba zamożnych pasażerów pierwszej klasy. Queenstown (Q) z kolei to port, w którym wsiadali głównie biedniejsi emigranci irlandzcy do klasy trzeciej, jednak ich szanse i tak były odrobinę lepsze niż w przypadku Southampton.



Wykres 4. Rozkład gęstości wieku. Widoczny pik w grupie dzieci (0-10 lat) potwierdza priorytet w ich ratowaniu.

```
# 4. Gęstość Wiek vs Przeżycie
plt.figure(figsize=(8, 5))
sns.kdeplot(data=df, x='age', hue='survived', fill=True, common_norm=False,
palette='Set2', alpha=0.5)
plt.title('Rozkład wieku w grupach (Ocalały vs Nieocalały)')
plt.savefig('eda_age_density.png', dpi=300)
plt.close()
```


Wykres gęstości (KDE) dla wieku to niezwykle ważne narzędzie pozwalające zrozumieć nieliniowy wpływ wieku na przetrwanie. Patrząc na lewą stronę osi X, natychmiast zauważamy ostry, wysoki „pik” dla krzywej ocalałych (kolor pomarańczowy) w przedziale od 0 do około 10 lat. Stanowi to matematyczny dowód na to, że niemowlęta i małe dzieci były bezwzględnie priorytetyzowane podczas umieszczania w szalupach ratunkowych. Zupełnie inaczej wygląda sytuacja w centralnej części wykresu, między 18 a 35 rokiem życia. W tym przedziale widoczny jest masywny wzrost gęstości dla krzywej ofiar (kolor niebieski), co oznacza, że to właśnie młodzi dorośli ponieśli najcięższe straty.



Wykres 5. Rozkład ceny biletu. Obszar najniższych cen biletów pokrywa się niemal w całości z gęstością dla ofiar śmiertelnych.

```
# 5. Gęstość Cena biletu vs Przeżycie
plt.figure(figsize=(8, 5))
df_fare_vis = df[df['fare'] < 200]
sns.kdeplot(data=df_fare_vis, x='fare', hue='survived', fill=True, common_norm=False,
palette='Set2', alpha=0.5)
plt.title('Rozkład ceny biletu w grupach (Ocalały vs Nieocalały)')
plt.savefig('eda_fare_density.png', dpi=300)
plt.close()
```

Ten wykres gęstości skupia się na cenie zapłaconej za bilet, która została obcięta do wartości 200 na potrzeby zachowania czytelności wizualizacji. Najbardziej uderzającym elementem jest gigantyczny pik dla krzywej ofiar (niebieski) zlokalizowany tuż przy zerze, w przedziale cenowym od 0 do około 15 funtów. Oznacza to, że przeważająca większość osób, które zginęły, posiadała najtańsze bilety, przypisane do najniższych klas. Z kolei krzywa reprezentująca ocalałych (pomarańczowa) jest znacznie bardziej wypłaszczona i rozciągnięta w prawą stronę. W miarę przesuwania się wzdłuż osi X ku wyższym cenom, powierzchnia pod krzywą ocalałych zaczyna dominować nad krzywą ofiar.




Wykres 6. Macierz korelacji Pearsona. Silna ujemna korelacja między `pclass` a `survived` jest kluczowym odkryciem analitycznym.

```
# 6. Macierz korelacji
plt.figure(figsize=(8, 6))
corr_df = df[['survived', 'pclass', 'age', 'sibsp', 'parch', 'fare']].corr()
sns.heatmap(corr_df, annot=True, cmap='coolwarm', fmt=".2f", vmin=-1, vmax=1)
plt.title('Macierz korelacji zmiennych numerycznych')
plt.tight_layout()
plt.savefig('eda_korelacja.png', dpi=300)
plt.close()
```

Analiza korelacji Pearsona ujawnia kilka kluczowych zależności w zbiorze danych. Najważniejszą z nich jest umiarkowana, ujemna korelacja (-0.31) pomiędzy klasą biletu (`pclass`) a statusem przeżycia (`survived`). Oznacza to, że pasażerowie podróżujący w wyższych klasach (o niższych numerach, np. klasa 1) mieli statystycznie większe szanse na ratunek. Z kolei korelacja dodatnia (0.24) między opłatą za bilet (`fare`) a przeżyciem potwierdza, że zamożność odgrywała istotną rolę. Warto również zauważyć silną ujemną korelację (-0.56) między `pclass` a `fare`, co jest zjawiskiem naturalnym (lepszą klasą oznacza droższy bilet). Zaskakująco niska korelacja liniowa między wiekiem (`age`) a przeżyciem (-0.06) sugeruje, że zależność ta ma charakter nieliniowy (np. ratowano głównie małe dzieci, ale dla reszty wiek nie gwarantował przeżycia). Idealnie uzasadnia to wykorzystanie w projekcie złożonych modeli, takich jak Las Losowy, które potrafią wyłapywać takie nieliniowe relacje.

6.2 Załącznik 2. Wyniki z działania modelu (Feature Importance i inne)



Wykres 7. Najważniejsze atrybuty decydujące o przeżyciu z perspektywy algorytmu Random Forest.

```
# Ważność cech (tylko dla Random Forest)
rf_model = models["Random Forest"]
feature_importances = pd.Series(
    rf_model.feature_importances_,
    index=X.columns
).sort_values(ascending=False).head(10)

plt.figure(figsize=(10, 6))
sns.barplot(
    x=feature_importances.values,
    y=feature_importances.index,
    hue=feature_importances.index,
    palette='viridis',
    legend=False
)
plt.title('Top 10 najważniejszych atrybutów (Random Forest)')
plt.xlabel('Feature Importance')
plt.tight_layout()
plt.savefig('waznosc_atrybutow_rf.png', dpi=300)
plt.close()
```

Wykres Feature Importance, wygenerowany na podstawie wag modelu Lasu Losowego, jednoznacznie pokazuje, które cechy miały największy wpływ na proces decyzyjny algorytmu. Zdecydowanym liderem jest zmienna określająca płeć męską (`sex_male`). Potwierdza to historyczną regułę „kobiety i dzieci najpierw” – bycie dorosłym mężczyzną okazało się najsilniejszym predyktorem śmierci w katastrofie. Na drugim miejscu uplasował się sztucznie wygenerowany wskaźnik MPC (wiek pomnożony przez klasę podróży), co stanowi doskonały dowód na to, że proces inżynierii cech (Feature Engineering) w sposób kluczowy przyczynił się do sukcesu modelu. Wysoko w rankingu znalazła się również cena biletu (`fare`) oraz tytuł grzecznościowy `Title_Mr`, co ponownie akcentuje pierwszorzędne znaczenie płci i statusu społecznego podczas akcji ratunkowej.